

# 数值计算

## 一、数值稳定性

### 1.1 近似误差

1. 在计算机中执行数学运算需要使用有限的比特位来表达实数，这会引入近似误差
  - 近似误差可以在多步数值运算中传递、积累，从而导致理论上成功的算法失败
  - 数值算法设计时要考虑将累计误差最小化
2. 上溢出 `overflow` 和下溢出 `underflow` :
  - 一种严重的误差是下溢出：当接近零的数字四舍五入为零时，发生下溢出
    - 许多函数在参数为零和参数为一个非常小的正数时，行为是不同的。如对数函数要求自变量大于零；除法中要求除数非零。
  - 另一种严重的误差是上溢出：当数值非常大，超过了计算机的表示范围时，发生上溢出。

### 1.2 softmax 函数

1. 一个数值稳定性的例子是 `softmax` 函数。

设  $\vec{x} = (x_1, x_2, \dots, x_n)^T$ ，则 `softmax` 函数定义为：

$$\text{softmax}(\vec{x}) = \left( \frac{\exp(x_1)}{\sum_{j=1}^n \exp(x_j)}, \frac{\exp(x_2)}{\sum_{j=1}^n \exp(x_j)}, \dots, \frac{\exp(x_n)}{\sum_{j=1}^n \exp(x_j)} \right)^T$$

当所有的  $x_i$  都等于常数  $c$  时，`softmax` 函数的每个分量的理论值都为  $\frac{1}{n}$

- 考虑  $c$  是一个非常大的负数（比如趋近负无穷），此时  $\exp(c)$  下溢出。此时  $\frac{\exp(c)}{\sum_{j=1}^n \exp(c)}$  分母为零，结果未定义。
  - 考虑  $c$  是一个非常大的正数（比如趋近正无穷），此时  $\exp(c)$  上溢出。  $\frac{\exp(c)}{\sum_{j=1}^n \exp(c)}$  的结果未定义。
2. 解决的办法是：令  $\vec{z} = \vec{x} - \max_i x_i$ ，则有 `softmax`( $\vec{z}$ ) 的第  $i$  个分量为：

$$\begin{aligned} \text{softmax}(\vec{z})_i &= \frac{\exp(z_i)}{\sum_{j=1}^n \exp(z_j)} = \frac{\exp(\max_k x_k) \exp(z_i)}{\exp(\max_k x_k) \sum_{j=1}^n \exp(z_j)} \\ &= \frac{\exp(z_i + \max_k x_k)}{\sum_{j=1}^n \exp(z_j + \max_k x_k)} \\ &= \frac{\exp(x_i)}{\sum_{j=1}^n \exp(x_j)} \\ &= \text{softmax}(\vec{x})_i \end{aligned}$$

- 当  $\vec{x}$  的分量较小时， $\vec{z}$  的分量至少有一个为零，从而导致 `softmax`( $\vec{z}$ ) $_i$  的分母至少有一项为 1，从而解决了下溢出的问题。
  - 当  $\vec{x}$  的分量较大时，`softmax`( $\vec{z}$ ) $_i$  相当于分子分母同时除以一个非常大的数  $\exp(\max_i x_i)$ ，从而解决了上溢出。
3. 还有个问题：当  $\vec{x}$  的分量较小时，`softmax`( $\vec{x}$ ) $_i$  的计算结果可能为 0。

- 此时  $\log \text{softmax}(\vec{x})$  趋向于负无穷，非数值稳定的。因此需要设计专门的函数来计算  $\log \text{softmax}$ ，而不是将  $\text{softmax}$  的结果传递给  $\log$  函数。

通常将  $\text{softmax}$  函数的输出作为模型的输出。由于一般使用样本的交叉熵作为目标函数，因此需要用到  $\text{softmax}$  输出的对数。

- 当从头开始实现一个数值算法时，需要考虑数值稳定性。

当使用现有的数值计算库时，不需要考虑数值稳定性。

- `softmax` 名字的来源是 `hardmax`。

`hardmax` 把一个向量  $\vec{x}$  映射成向量  $(0, \dots, 0, 1, 0, \dots, 0)^T$ 。即： $\vec{x}$  最大元素的位置填充 1，其它位置填充 0。

`softmax` 会在这些位置填充 0.0~1.0 之间的值（如：某个概率值）。

## 二、Conditioning

- `Conditioning` 刻画了一个函数的如下特性：当函数的输入发生了微小的变化时，函数的输出的变化有多大。
  - 对于 `Conditioning` 较大的函数，在数值计算中可能有问题。因为函数输入的舍入误差可能导致函数输出的较大变化。
- 对于方阵  $\mathbf{A} \in \mathbb{R}^{n \times n}$ ，其条件数 `condition number` 为：

$$\text{condition number} = \max_{1 \leq i, j \leq n, i \neq j} \left| \frac{\lambda_i}{\lambda_j} \right|$$

其中  $\lambda_i, i = 1, 2, \dots, n$  为  $\mathbf{A}$  的特征值。

- 方阵的条件数就是最大的特征值除以最小的特征值。
- 当方阵的条件数很大时，矩阵的求逆将对误差特别敏感（即： $\mathbf{A}$  的一个很小的扰动，将导致其逆矩阵一个非常明显的变化）。
- 条件数是矩阵本身的特性，它会放大那些包含矩阵求逆运算过程中的误差。

## 三、梯度下降法

- 梯度下降法是求解无约束最优化问题的一种常见方法，优点是实现简单
- 对于函数： $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，输入为多维的。假设输入  $\vec{x} = (x_1, x_2, \dots, x_n)^T$ ，则定义梯度：

$$\nabla_{\vec{x}} f(\vec{x}) = \left( \frac{\partial}{\partial x_1} f(\vec{x}), \frac{\partial}{\partial x_2} f(\vec{x}), \dots, \frac{\partial}{\partial x_n} f(\vec{x}) \right)^T$$

- 驻点满足： $\nabla_{\vec{x}} f(\vec{x}) = \vec{0}$

- 沿着方向  $\vec{u}$  的方向导数 `directional derivative` 定义为：

$$\lim_{\alpha \rightarrow 0} \frac{f(\vec{x} + \alpha \vec{u}) - f(\vec{x})}{\alpha}$$

其中  $\vec{u}$  为单位向量。

- 方向导数就是  $\frac{\partial}{\partial \alpha} f(\vec{x} + \alpha \vec{u})$ 。根据链式法则，它也等于  $\vec{u}^T \nabla_{\vec{x}} f(\vec{x})$

- 为了最小化  $f$ ，则寻找一个方向：沿着该方向，函数值减少的速度最快（换句话说，就是增加最慢）。即：

$$\begin{aligned} \min_{\vec{u}} \quad & \vec{u}^T \nabla_{\vec{x}} f(\vec{x}) \\ \text{s.t.} \quad & \|\vec{u}\|_2 = 1 \end{aligned}$$

- 假设  $\vec{u}$  与梯度的夹角为  $\theta$ ，则目标函数等于：

$$\|\vec{u}\|_2 \|\nabla_{\vec{x}} f(\vec{x})\|_2 \cos \theta$$

考虑到  $\|\vec{u}\|_2 = 1$ ，以及梯度的大小与  $\theta$  无关，于是上述问题转化为：

$$\min_{\theta} \cos \theta$$

于是： $\theta^* = \pi$ ，即  $\vec{u}$  沿着梯度的相反的方向。

即：梯度的方向是函数值增加最快的方向，梯度的相反方向是函数值减小的最快的方向。

- 可以沿着负梯度的方向来降低  $f$  的值，这就是梯度下降法。

4. 根据梯度下降法，为了寻找  $f$  的最小点，迭代过程为：

$$\vec{x}' = \vec{x} - \epsilon \nabla_{\vec{x}} f(\vec{x})$$

迭代结束条件为：梯度向量  $\nabla_{\vec{x}} f(\vec{x})$  的每个成分为零或者非常接近零。

- $\epsilon$  为学习率，它是一个正数，决定了迭代的步长。

5. 选择学习率有多种方法：

- 一种方法是：选择  $\epsilon$  为一个小的、正的常数
- 另一种方法是：给定多个  $\epsilon$ ，然后选择使得  $f(\vec{x} - \epsilon \nabla_{\vec{x}} f(\vec{x}))$  最小的那个值作为本次迭代的学习率（即：选择一个使得目标函数下降最大的学习率）。这种做法叫做线性搜索 `line search`
- 第三种方法是：求得使  $f(\vec{x} - \epsilon \nabla_{\vec{x}} f(\vec{x}))$  取极小值的  $\epsilon$ ，即求解最优化问题：

$$\epsilon^* = \arg \min_{\epsilon, \epsilon > 0} f(\vec{x} - \epsilon \nabla_{\vec{x}} f(\vec{x}))$$

这种方法也称作最速下降法。

- 在最速下降法中，假设相邻的三个迭代点分别为： $\vec{x}^{<k>}$ ,  $\vec{x}^{<k+1>}$ ,  $\vec{x}^{<k+2>}$ ，可以证明： $(\vec{x}^{<k+1>} - \vec{x}^{<k>}) \cdot (\vec{x}^{<k+2>} - \vec{x}^{<k+1>}) = 0$ 。即相邻的两次搜索的方向是正交的！

证明：

$$\begin{aligned} \vec{x}^{<k+1>} &= \vec{x}^{<k>} - \epsilon^{<k>} \nabla_{\vec{x}} f(\vec{x}^{<k>}) \\ \vec{x}^{<k+2>} &= \vec{x}^{<k+1>} - \epsilon^{<k+1>} \nabla_{\vec{x}} f(\vec{x}^{<k+1>}) \end{aligned}$$

根据最优化问题，有：

$$\begin{aligned} \epsilon^{<k+1>} &= \arg \min_{\epsilon, \epsilon > 0} f(\vec{x}^{<k+1>} - \epsilon \nabla_{\vec{x}} f(\vec{x}^{<k+1>})) \\ &\rightarrow \frac{\partial f(\vec{x}^{<k+1>} - \epsilon \nabla_{\vec{x}} f(\vec{x}^{<k+1>}))}{\partial \epsilon} \Big|_{\epsilon = \epsilon^{<k+1>}} = 0 \\ &\rightarrow \nabla_{\vec{x}} f(\vec{x}^{<k+2>}) \cdot \nabla_{\vec{x}} f(\vec{x}^{<k+1>}) = 0 \\ &\rightarrow (\vec{x}^{<k+1>} - \vec{x}^{<k>}) \cdot (\vec{x}^{<k+2>} - \vec{x}^{<k+1>}) = 0 \end{aligned}$$

- 此时迭代的路线是锯齿形的，因此收敛速度较慢

6. 某些情况下如果梯度向量  $\nabla_{\vec{x}} f(\vec{x})$  的形式比较简单，则可以直接求解方程：

$$\nabla_{\vec{x}} f(\vec{x}) = \vec{0}$$

- 此时不用任何迭代，直接获得解析解。

#### 7. 梯度下降算法：

- 输入：

- 目标函数  $f(\vec{x})$
- 梯度函数  $g(\vec{x}) = \nabla f(\vec{x})$
- 计算精度  $e$

- 输出：  $f(\vec{x})$  的极小点  $\vec{x}^*$

- 算法步骤：

- 选取初始值  $\vec{x}^{<0>} \in \mathbb{R}^n$ , 置  $k = 0$

- 计算  $f(\vec{x}^{<k>})$

- 计算梯度  $\vec{g}_k = g(\vec{x}^{<k>})$

- 若梯度  $|\vec{g}_k| < e$ , 则停止迭代,  $\vec{x}^* = \vec{x}$

即此时导数为 0


- 若梯度  $|\vec{g}_k| \geq e$ , 则令  $\vec{p}_k = -\vec{g}_k$ , 求  $\epsilon_k$  :  $\epsilon_k = \min_{\epsilon \leq 0} f(\vec{x}^{<k>} + \epsilon \vec{p}_k)$

通常这也是个最小化问题。但是可以给定一系列的  $\epsilon_k$  的值：如

`[10, 1, 0.1, 0.01, 0.001, 0.0001]` 然后从中挑选

- 令  $\vec{x}^{<k+1>} = \vec{x}^{<k>} + \epsilon_k \vec{p}_k$ , 计算  $f(\vec{x}^{<k+1>})$

- 若  $|f(\vec{x}^{<k+1>}) - f(\vec{x}^{<k>})| < e$  或者  $|\vec{x}^{<k+1>} - \vec{x}^{<k>}| < e$  时, 停止迭代,  $\vec{x}^* = \vec{x}$
- 否则, 令  $k = k + 1$ , 计算梯度  $\vec{g}_k = g(\vec{x}^{<k>})$  继续迭代



#### 8. 当目标函数是凸函数时，梯度下降法的解是全局最优的。

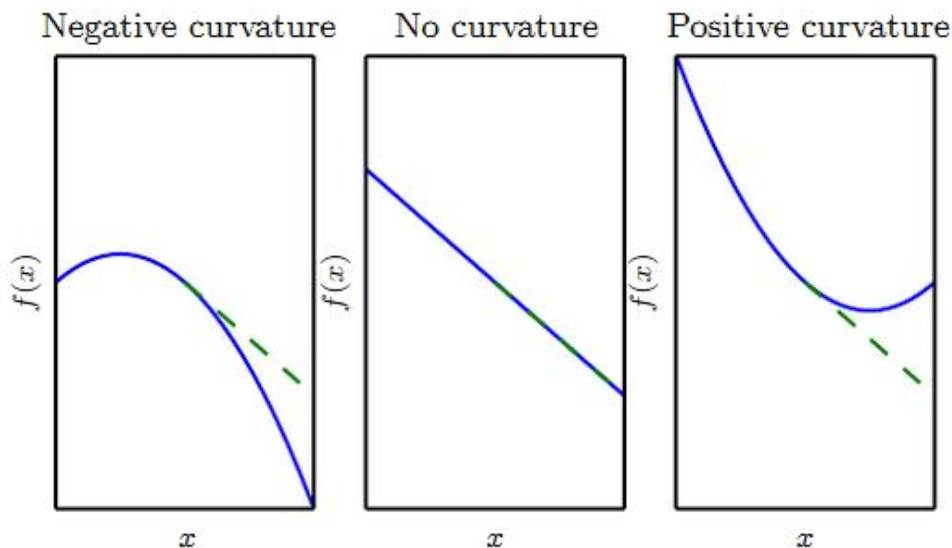
- 通常情况下，梯度下降法的解不保证是全局最优的
- 梯度下降法的收敛速度未必是最快的

## 四、海森矩阵

## 4.1 二阶导数

1. 二阶导数  $f''(x)$  刻画了曲率。假设有一个二次函数（实际任务中，很多函数不是二次的，但是在局部可以近似为二次函数）：

- 如果函数的二阶导数为零，则它是一条直线。如果梯度为 1，则当沿着负梯度的步长为  $\epsilon$  时，函数值减少  $\epsilon$
- 如果函数的二阶导数为负，则函数向下弯曲。如果梯度为 1，则当沿着负梯度的步长为  $\epsilon$  时，函数值减少的量大于  $\epsilon$
- 如果函数的二阶导数为正，则函数向上弯曲。如果梯度为 1，则当沿着负梯度的步长为  $\epsilon$  时，函数值减少的量少于  $\epsilon$



## 4.2 海森矩阵

1. 当函数输入为多维时，定义海森矩阵：

$$\mathbf{H}(f)(\vec{\mathbf{x}}) = \begin{bmatrix} \frac{\partial^2}{\partial x_1 \partial x_1} f & \frac{\partial^2}{\partial x_1 \partial x_2} f & \cdots & \frac{\partial^2}{\partial x_1 \partial x_n} f \\ \frac{\partial^2}{\partial x_2 \partial x_1} f & \frac{\partial^2}{\partial x_2 \partial x_2} f & \cdots & \frac{\partial^2}{\partial x_2 \partial x_n} f \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2}{\partial x_n \partial x_1} f & \frac{\partial^2}{\partial x_n \partial x_2} f & \cdots & \frac{\partial^2}{\partial x_n \partial x_n} f \end{bmatrix}$$

即海森矩阵的第  $i$  行  $j$  列元素为：

$$\mathbf{H}_{i,j} = \frac{\partial^2}{\partial x_i \partial x_j} f(\vec{\mathbf{x}})$$

- 当二阶偏导是连续时，海森矩阵是对称阵，即有：  $\mathbf{H} = \mathbf{H}^T$

■ 在深度学习中大多数海森矩阵都是对称阵

2. 对于特定方向  $\vec{\mathbf{d}}$  上的二阶导数为：

$$\vec{\mathbf{d}}^T \mathbf{H} \vec{\mathbf{d}}$$

- 如果  $\vec{\mathbf{d}}$  是海森矩阵的特征向量，则该方向上的二阶导数就是对应的特征值

- 如果  $\vec{d}$  不是海森矩阵的特征向量，则该方向的二阶导数就是所有特征值的加权平均，权重在  $(0,1)$  之间。且与  $\vec{d}$  夹角越小的特征向量对应的特征值具有更大的权重。
- 最大特征值确定了最大二阶导数，最小特征值确定最小二阶导数

### 4.3 海森矩阵与学习率

1. 将  $f(\vec{x})$  在  $\vec{x}_0$  处泰勒展开：

$$f(\vec{x}) \approx f(\vec{x}_0) + (\vec{x} - \vec{x}_0)^T \vec{g} + \frac{1}{2}(\vec{x} - \vec{x}_0)^T \mathbf{H}(\vec{x} - \vec{x}_0)$$

其中  $\vec{g}$  为  $\vec{x}_0$  处的梯度； $\mathbf{H}$  为  $\vec{x}_0$  处的海森矩阵。

根据梯度下降法：

$$\vec{x}' = \vec{x} - \epsilon \nabla_{\vec{x}} f(\vec{x})$$

应用在点  $\vec{x}_0$ ，有：

$$f(\vec{x}_0 - \epsilon \vec{g}) \approx f(\vec{x}_0) - \epsilon \vec{g}^T \vec{g} + \frac{1}{2} \epsilon^2 \vec{g}^T \mathbf{H} \vec{g}$$

- 第一项代表函数在点  $\vec{x}_0$  处的值
  - 第二项代表由于斜率的存在，导致函数值的变化
  - 第三项代表由于曲率的存在，对于函数值变化的矫正
2. 注意：如果  $\frac{1}{2} \epsilon^2 \vec{g}^T \mathbf{H} \vec{g}$  较大，则很有可能导致：沿着负梯度的方向，函数值反而增加！
- 如果  $\vec{g}^T \mathbf{H} \vec{g} \leq 0$ ，则无论  $\epsilon$  取多大的值，可以保证函数值是减小的
  - 如果  $\vec{g}^T \mathbf{H} \vec{g} > 0$ ，则学习率  $\epsilon$  不能太大。若  $\epsilon$  太大则函数值增加
    - 根据  $f(\vec{x}_0 - \epsilon \vec{g}) - f(\vec{x}_0) < 0$  有：

$$\epsilon < \frac{2\vec{g}^T \vec{g}}{\vec{g}^T \mathbf{H} \vec{g}}$$

- 考虑最速下降法，选择使得  $f$  下降最快的  $\epsilon$ ，则有：

$$\epsilon^* = \arg \min_{\epsilon, \epsilon > 0} f(\vec{x}_0 - \epsilon \vec{g})$$

求解  $\frac{\partial}{\partial \epsilon} f(\vec{x}_0 - \epsilon \vec{g}) = 0$  有：

$$\epsilon^* = \frac{\vec{g}^T \vec{g}}{\vec{g}^T \mathbf{H} \vec{g}}$$

根据  $\vec{g}^T \mathbf{H} \vec{g} > 0$ ，很明显有： $\epsilon^* < \frac{2\vec{g}^T \vec{g}}{\vec{g}^T \mathbf{H} \vec{g}}$

3. 由于海森矩阵为实对称阵，因此它可以进行特征值分解。

假设其特征值从大到小排列为：

$$\lambda_1, \lambda_2, \dots, \lambda_n$$

其瑞利商为  $R(\vec{x}) = \frac{\vec{x}^T \mathbf{H} \vec{x}}{\vec{x}^T \vec{x}}$ ,  $\vec{x} \neq \vec{0}$ ，可以证明：

$$\lambda_n \leq R(\vec{x}) \leq \lambda_1$$

$$\lambda_1 = \max_{\vec{x} \neq \vec{0}} R(\vec{x})$$

$$\lambda_n = \min_{\vec{x} \neq \vec{0}} R(\vec{x})$$

根据：

$$\epsilon^* = \frac{\vec{g}^T \vec{g}}{\vec{g}^T \mathbf{H} \vec{g}} = \frac{1}{R(\vec{g})}$$


可知海森矩阵决定了学习率的取值范围。

- 最坏的情况下，梯度  $\vec{g}$  与海森矩阵最大特征值  $\lambda_1$  对应的特征向量平行，则此时最优学习率为  $\frac{1}{\lambda_1}$

## 4.4 驻点与全局极小点

1. 满足导数为零的点（即  $f'(x) = 0$ ）称作驻点。驻点可能为下面三种类型之一：

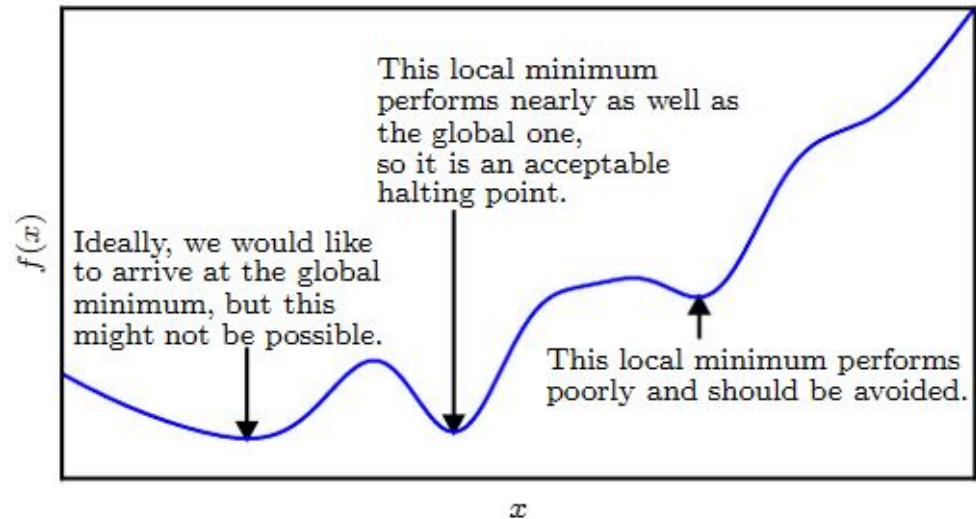
- 局部极小点：在  $x$  的一个邻域内，该点的值最小
- 局部极大点：在  $x$  的一个邻域内，该点的值最大
- 鞍点：既不是局部极小，也不是局部极大



2. 全局极小点： $x^* = \arg \min_x f(x)$ 。

- 全局极小点可能有一个或者多个
- 在深度学习中，目标函数很可能具有非常多的局部极小点，以及许多位于平坦区域的鞍点。这使得优化非常不利。因此通常选取一个非常低的目标函数值，而不一定要全局最小值。





3. 二阶导数可以配合一阶导数来决定驻点的类型：


- 局部极小点：  $f'(x) = 0, f''(x) > 0$
- 局部极大点：  $f'(x) = 0, f''(x) < 0$
- $f'(x) = 0, f''(x) = 0$ ：驻点的类型可能为任意三者之一。

4. 对于多维的情况类似：

- 局部极小点：  $\nabla_{\vec{x}} f(\vec{x}) = 0$ ，且海森矩阵为正定的（即所有的特征值都是正的）。
  - 当海森矩阵为正定时，任意方向的二阶偏导数都是正的。
- 局部极大点：  $\nabla_{\vec{x}} f(\vec{x}) = 0$ ，且海森矩阵为负定的（即所有的特征值都是负的）。
  - 当海森矩阵为负定时，任意方向的二阶偏导数都是负的。
- $\nabla_{\vec{x}} f(\vec{x}) = 0$ ，且海森矩阵的特征值中至少一个正值、至少一个负值时，为鞍点。
- 当海森矩阵非上述情况时，驻点类型无法判断。

下图为  $f(\vec{x}) = x_1^2 - x_2^2$  在原点附近的等值线。其海森矩阵为一正一负。

- 沿着  $x_1$  方向，曲线向上；沿着  $x_2$  方向，曲线向下。
- 鞍点就是在一个横截面内的局部极小值，另一个横截面内的局部极大值。





## 四、牛顿法

### 1. 梯度下降法有个缺陷：它未能利用海森矩阵的信息

- 当海森矩阵的条件数较大时，不同方向的梯度的变化差异很大。
  - 在某些方向上，梯度变化很快；在有些方向上，梯度变化很慢
  - 梯度下降法未能利用海森矩阵，也就不知道应该优先搜索导数长期为负的方向。


本质上应该沿着负梯度方向搜索。但是沿着该方向的一段区间内，如果导数一直为负，则可以直接跨过该区间。前提是：必须保证该区间内，该方向导数一直为负。

- 当海森矩阵的条件数较大时，也难以选择合适的步长。
  - 步长必须足够小，从而能够适应较强曲率的地方（对应着较大的二阶导数，即该区域比较陡峭）
  - 但是如果步长太小，对于曲率较小的地方（对应着较小的二阶导数，即该区域比较平缓）则推进太慢。

曲率刻画弯曲程度，曲率越大则曲率半径越小

### 2. 下图是利用梯度下降法寻找函数最小值的路径。

- 该函数是二次函数，海森矩阵条件数为 5，表明最大曲率是最小曲率的5倍。
- 红线为梯度下降的搜索路径。（它没有用最速下降法，而是用到线性搜索。如果是最速下降法，则相邻两次搜索的方向正交）



### 3. 牛顿法结合了海森矩阵。

考虑泰勒展开式：

$$f(\vec{x}) \approx f(\vec{x}_0) + (\vec{x} - \vec{x}_0)^T \vec{g} + \frac{1}{2} (\vec{x} - \vec{x}_0)^T \mathbf{H} (\vec{x} - \vec{x}_0)$$


其中  $\vec{g}$  为  $\vec{x}_0$  处的梯度； $\mathbf{H}$  为  $\vec{x}_0$  处的海森矩阵。

如果  $\vec{x}$  为极值点，则有：  $\frac{\partial}{\partial \vec{x}} f(\vec{x}) = \vec{0}$ ，则有：

$$\vec{x}^* = \vec{x}_0 - \mathbf{H}^{-1} \vec{g}$$

- 当  $f$  是个正定的二次型，则牛顿法直接一次就能到达最小值点
- 当  $f$  不是正定的二次型，则可以在局部近似为正定的二次型，那么则采用多次牛顿法即可到达最小值点。

#### 4. 一维情况下，梯度下降法和牛顿法的原理展示：



- 梯度下降法：下一次迭代的点  $\vec{x}^{<k+1>} = \vec{x}^{<k>} - \epsilon_k \nabla f(\vec{x})$ .
  - 对于一维的情况，可以固定  $\epsilon_k = \eta$ ，由于随着迭代的推进， $f'(x)$  绝对值是减小的（直到0），因此越靠近极值点， $\Delta(x)$  越小
- 牛顿法：目标是  $\nabla f(\vec{x}) = 0$ 。在一维情况下就是求解  $f'(x) = 0$ 。牛顿法的方法是：以  $x = x^{<k>}$  做  $y = f'(x)$  切线，该切线过点  $(x^{<k>}, f'(x^{<k>}))$ 。该切线在  $x$  轴上的交点就是

$$x^{<k+1>} = x^{<k>} - \frac{f'(x^{<k>})}{f''(x^{<k>})}$$

推广到多维情况下就是：

$$\vec{x}^{<k+1>} = \vec{x}^{<k>} - \mathbf{H}_k^{-1} \vec{g}_k$$

#### 5. 当位于一个极小值点附近时，牛顿法比梯度下降法能更快地到达极小值点。

- 如果在一个鞍点附近，牛顿法效果很差；而梯度下降法此时效果较好（除非负梯度的方向刚好指向了鞍点）。
- 6. 仅仅利用了梯度的优化算法（如梯度下降法）称作一阶优化算法；同时利用了海森矩阵的优化算法（如牛顿法）称作二阶优化算法

#### 7. 牛顿法算法：

- 输入：
  - 目标函数  $f(\vec{x})$
  - 梯度  $g(\vec{x}) = \nabla f(\vec{x})$
  - 海森矩阵  $\mathbf{H}(\vec{x})$
  - 精度要求  $e$
- 输出：  $f(\vec{x})$  的极小值点  $\vec{x}^*$

○ 算法步骤:


- 选取初始值  $\vec{x}^{<0>} \in \mathbb{R}^n$ , 置  $k = 0$
- 计算  $\vec{g}_k = g(\vec{x}^{<k>})$ 
  - 若  $|\vec{g}_k| < e$ , 则停止计算, 得到近似解  $\vec{x} = \vec{x}^*$
  - 若  $|\vec{g}_k| \geq e$ , 则:
    - 计算  $\mathbf{H}_k = \mathbf{H}(\vec{x}^{<k>})$ , 并求  $\vec{p}_k, \mathbf{H}_k \vec{p}_k = -\vec{g}_k$
    - 置  $\vec{x}^{<k+1>} = \vec{x}^{<k>} + \vec{p}_k$
    - 置  $k = k + 1$ , 计算  $\vec{g}_k = g(\vec{x}^{<k>})$ , 迭代

8. 梯度下降法中, 每一次  $\vec{x}$  增加的方向一定是梯度相反的方向  $-\epsilon_k \nabla_k$

- 增加的幅度由  $\epsilon_k$  决定, 若跨度过大容易引发震荡;

而牛顿法中, 每一次  $\vec{x}$  增加的方向是梯度增速最大的反方向  $-\mathbf{H}_k^{-1} \nabla_k$  (它通常情况下与梯度不共线)

- 增加的幅度已经包含在  $\mathbf{H}_k^{-1}$  中 (也可以乘以学习率作为幅度的系数)



9. 深度学习中的目标函数非常复杂, 无法保证可以通过上述优化算法进行优化。因此有时会限定目标函数具有 Lipschitz 连续, 或者其导数 Lipschitz 连续。

- Lipschitz 连续的定义: 对于函数  $f$ , 存在一个 Lipschitz 常数  $\mathcal{L}$ , 使得

$$\forall \vec{x}, \forall \vec{y}, |f(\vec{x}) - f(\vec{y})| \leq \mathcal{L} \|\vec{x} - \vec{y}\|_2$$

- Lipschitz 连续的意义是: 输入的一个很小的变化, 会引起输出的一个很小的变化。

与之相反的是: 输入的一个很小的变化, 会引起输出的一个很大的变化

10. 凸优化在某些特殊的领域取得了巨大的成功。但是在深度学习中, 大多数优化问题都难以用凸优化来描述。

凸优化的重要性在深度学习中大大降低。凸优化仅作为一些深度学习算法的子程序。

## 五、拟牛顿法

### 5.1 原理

1. 在牛顿法的迭代中, 需要计算海森矩阵的逆矩阵  $\mathbf{H}^{-1}$ , 这一计算比较复杂。

◦ 可以考虑用一个  $n$  阶矩阵  $\mathbf{G}_k = G(\vec{x}^{<k>})$  来近似代替  $\mathbf{H}_k^{-1} = H^{-1}(\vec{x}^{<k>})$ 。

2. 先看海森矩阵满足的条件:  $\vec{g}_{k+1} - \vec{g}_k = \mathbf{H}_k(\vec{x}^{<k+1>} - \vec{x}^{<k>})$

◦ 令  $\vec{y}_k = \vec{g}_{k+1} - \vec{g}_k$ ,  $\vec{\delta}_k = \vec{x}^{<k+1>} - \vec{x}^{<k>}$  则有:  $\vec{y}_k = \mathbf{H}_k \vec{\delta}_k$ , 或者  $\mathbf{H}_k^{-1} \vec{y}_k = \vec{\delta}_k$ 。这称为拟牛顿条件

◦ 根据牛顿法的迭代:  $\vec{x}^{<k+1>} = \vec{x}^{<k>} - \mathbf{H}_k^{-1} \vec{g}_k$ , 将  $f(\vec{x})$  在  $\vec{x}^{<k>}$  的一阶泰勒展开:

$$\begin{aligned} f(\vec{x}^{<k+1>}) &= f(\vec{x}^{<k>}) + f'(\vec{x}^{<k>})(\vec{x}^{<k+1>} - \vec{x}^{<k>}) \\ &= f(\vec{x}^{<k>}) + \vec{g}_k^T (-\mathbf{H}_k^{-1} \vec{g}_k) = f(\vec{x}^{<k>}) - \vec{g}_k^T \mathbf{H}_k^{-1} \vec{g}_k \end{aligned}$$

当  $\mathbf{H}_k$  是正定矩阵时, 总有  $f(\vec{x}^{<k+1>}) < f(\vec{x}^{<k>})$ , 因此每次都是沿着函数递减的方向迭代

3. 拟牛顿法如果选择  $\mathbf{G}_k$  作为  $\mathbf{H}_k^{-1}$  的近似时,  $\mathbf{G}_k$  同样要满足两个条件:

◦  $\mathbf{G}_k$  必须是正定的

◦  $\mathbf{G}_k$  满足拟牛顿条件:  $\mathbf{G}_{k+1} \vec{y}_k = \vec{\delta}_k$

因为  $\mathbf{G}_0$  是给定的初始化条件, 所以下标从  $k+1$  开始

按照拟牛顿条件, 在每次迭代中可以选择更新矩阵  $\mathbf{G}_{k+1} = \mathbf{G}_k + \Delta \mathbf{G}_k$

4. 正定矩阵定义: 设  $\mathbf{M}$  是  $n \times n$  阶方阵, 如果对于任何非零向量  $\vec{x}$ , 都有  $\vec{x}^T \mathbf{M} \vec{x} > 0$ , 就称  $\mathbf{M}$  正定矩阵

◦ 正定矩阵判定:

■ 判定定理1: 对称阵  $\mathbf{M}$  为正定的充分必要条件是:  $\mathbf{M}$  的特征值全为正。

■ 判定定理2: 对称阵  $\mathbf{M}$  为正定的充分必要条件是:  $\mathbf{M}$  的各阶顺序主子式都为正。

■ 判定定理3: 任意阵  $\mathbf{M}$  为正定的充分必要条件是:  $\mathbf{M}$  合同于单位阵。

◦ 正定矩阵的性质:

■ 正定矩阵一定是非奇异的。奇异矩阵的定义: 若  $n \times n$  阶矩阵  $\mathbf{M}$  为奇异阵, 则其的行列式为零, 即  $|\mathbf{M}| = 0$ 。

■ 正定矩阵的任一主子矩阵也是正定矩阵。

■ 若  $\mathbf{M}$  为  $n \times n$  阶对称正定矩阵, 则存在唯一的主对角线元素都是正数的下三角阵  $\mathbf{L}$ , 使得  $\mathbf{M} = \mathbf{L} \mathbf{L}^T$ , 此分解式称为 正定矩阵的乔列斯基 (Cholesky) 分解。

■ 若  $\mathbf{M}$  为  $n \times n$  阶正定矩阵, 则  $\mathbf{M}$  为  $n \times n$  阶可逆矩阵。

◦ 正定矩阵在某个合同变换下可化为标准型, 即对角矩阵。

◦ 所有特征值大于零的对称矩阵也是正定矩阵。

5. 合同矩阵: 两个实对称矩阵  $\mathbf{A}$  和  $\mathbf{B}$  是合同的, 当且仅当存在一个可逆矩阵  $\mathbf{P}$ , 使得  $\mathbf{A} = \mathbf{P}^T \mathbf{B} \mathbf{P}$

◦  $\mathbf{A}$  的合同变换: 对某个可逆矩阵  $\mathbf{P}$ , 对  $\mathbf{A}$  执行  $\mathbf{P}^T \mathbf{A} \mathbf{P}$

## 5.2 DFP 算法

1. DFP算法( Davidon-Fletcher-Powell ) 选择  $\mathbf{G}_{k+1}$  的方法是:

假设每一步迭代中  $\mathbf{G}_{k+1}$  是由  $\mathbf{G}_k$  加上两个附加项构成:  $\mathbf{G}_{k+1} = \mathbf{G}_k + \mathbf{P}_k + \mathbf{Q}_k$ , 其中  $\mathbf{P}_k, \mathbf{Q}_k$  是待定矩阵。此时有:  $\mathbf{G}_{k+1} \vec{y}_k = \mathbf{G}_k \vec{y}_k + \mathbf{P}_k \vec{y}_k + \mathbf{Q}_k \vec{y}_k$ 。

为了满足拟牛顿条件, 可以取:  $\mathbf{P}_k \vec{y}_k = \vec{\delta}_k$ ,  $\mathbf{Q}_k \vec{y}_k = -\mathbf{G}_k \vec{y}_k$ 。

2. 这样的  $\mathbf{P}_k, \mathbf{Q}_k$  不止一个。例如取

$$\mathbf{P}_k = \frac{\vec{\delta}_k \vec{\delta}_k^T}{\vec{\delta}_k^T \vec{y}_k}, \quad \mathbf{Q}_k = -\frac{\mathbf{G}_k \vec{y}_k \vec{y}_k^T \mathbf{G}_k}{\vec{y}_k^T \mathbf{G}_k \vec{y}_k}$$

这里  $\vec{\delta}_k, \vec{y}_k$  都是列向量

则迭代公式为:

$$\mathbf{G}_{k+1} = \mathbf{G}_k + \frac{\vec{\delta}_k \vec{\delta}_k^T}{\vec{\delta}_k^T \vec{y}_k} - \frac{\mathbf{G}_k \vec{y}_k \vec{y}_k^T \mathbf{G}_k}{\vec{y}_k^T \mathbf{G}_k \vec{y}_k}$$

其中的向量  $\vec{\delta}_k, \vec{y}_k$  都是列向量

3. 可以证明, 如果初始矩阵  $\mathbf{G}_0$  是正定的, 则迭代过程中每个矩阵  $\mathbf{G}_k$  都是正定的

4. DFP算法:

◦ 输入:


- 目标函数  $f(\vec{x})$
- 梯度  $g(\vec{x}) = \nabla f(\vec{x})$
- 精度要求  $e$

◦ 输出:  $f(\vec{x})$  的极小值点  $\vec{x}^*$

◦ 算法步骤:

- 选取初始值  $\vec{x}^{<0>} \in \mathbb{R}^n$ , 取  $\mathbf{G}_0$  为正定对称矩阵, 置  $k=0$
- 计算  $\vec{g}_k = g(\vec{x}^{<k>})$ 
  - 若  $|\vec{g}_k| < e$ , 则停止计算, 得到近似解  $\vec{x} = \vec{x}^*$
  - 若  $|\vec{g}_k| \geq e$ , 则:
    - 计算  $\vec{p}_k = -\mathbf{G}_k \vec{g}_k$
    - 一维搜索: 求  $\epsilon_k: \epsilon_k = \min_{\epsilon \geq 0} f(\vec{x}^{<k>} + \epsilon \vec{p}_k)$
    - 设置  $\vec{x}^{<k+1>} = \vec{x}^{<k>} + \epsilon_k \vec{p}_k$
    - 计算  $\vec{g}_{k+1} = g(\vec{x}^{<k+1>})$ . 若  $|\vec{g}_{k+1}| < \epsilon$ , 则停止计算, 得到近似解  $\vec{x} = \vec{x}^*$
    - 否则计算  $\mathbf{G}_{k+1}$ , 置  $k = k + 1$ , 计算  $\vec{p}_k = -\mathbf{G}_k \vec{g}_k$  迭代

5. DFP算法中, 每一次  $\vec{x}$  增加的方向是  $-\mathbf{G}_k \nabla_k$  的方向。增加的幅度由  $\epsilon_k$  决定, 若跨度过大容易引发震荡



## 5.2 BFGS 算法

1. BFGS是最流行的拟牛顿算法。DFP算法中，用  $\mathbf{G}_k$  逼近  $\mathbf{H}^{-1}$ 。换个角度可以用矩阵  $\mathbf{B}_k$  逼近海森矩阵  $\mathbf{H}$ 。此时对应的拟牛顿条件为： $\mathbf{B}_{k+1}\vec{\delta}_k = \vec{y}_k$ 。

因为  $\mathbf{B}_0$  是给定的初始化条件，所以下标从  $k+1$  开始

2. 令： $\mathbf{B}_{k+1} = \mathbf{B}_k + \mathbf{P}_k + \mathbf{Q}_k$ ，有： $\mathbf{B}_{k+1}\vec{\delta}_k = \mathbf{B}_k\vec{\delta}_k + \mathbf{P}_k\vec{\delta}_k + \mathbf{Q}_k\vec{\delta}_k$

可以取  $\mathbf{P}_k\vec{\delta}_k = \vec{y}_k$ ， $\mathbf{Q}_k\vec{\delta}_k = -\mathbf{B}_k\vec{\delta}_k$ 。寻找合适的  $\mathbf{P}_k, \mathbf{Q}_k$ ，可以得到 BFGS算法矩阵的  $\mathbf{B}_{k+1}$  的迭代公式：

$$\mathbf{B}_{k+1} = \mathbf{B}_k + \frac{\vec{y}_k\vec{y}_k^T}{\vec{y}_k^T\vec{\delta}_k} - \frac{\mathbf{B}_k\vec{\delta}_k\vec{\delta}_k^T\mathbf{B}_k}{\vec{\delta}_k^T\mathbf{B}_k\vec{\delta}_k}$$

其中的向量  $\vec{\delta}_k, \vec{y}_k$  都是列向量

3. 可以证明，若  $\mathbf{B}_0$  是正定的，则迭代过程中每个矩阵  $\mathbf{B}_k$  都是正定的。
4. BFGS算法：

◦ 输入：

- 目标函数  $f(\vec{x})$
- 梯度  $g(\vec{x}) = \nabla f(\vec{x})$
- 精度要求  $e$

◦ 输出： $f(\vec{x})$  的极小值点  $\vec{x}^*$


◦ 算法步骤：

- 选取初始值  $\vec{x}^{<0>} \in \mathbb{R}^n$ ，取  $\mathbf{B}_0$  为正定对称矩阵，置  $k=0$
- 计算  $\vec{g}_k = g(\vec{x}^{<k>})$ 
  - 若  $|\vec{g}_k| < e$ ，则停止计算，得到近似解  $\vec{x} = \vec{x}^*$
  - 若  $|\vec{g}_k| \geq e$ ，则：
    - 由  $\mathbf{B}_k\vec{p}_k = -\vec{g}_k$  求出  $\vec{p}_k$

这里表面上看需要对矩阵求逆。但是实际上  $\mathbf{B}_k^{-1}$  有迭代公式。根据 Sherman-Morrison 公式以及  $\mathbf{B}_k$  的迭代公式，可以得到  $\mathbf{B}_k^{-1}$  的迭代公式

- 一维搜索：求  $\epsilon_k$ ：  $\epsilon_k = \min_{\epsilon \geq 0} f(\bar{\mathbf{x}}^{<k>} + \epsilon \bar{\mathbf{p}}_k)$
- 设置  $\bar{\mathbf{x}}^{<k+1>} = \bar{\mathbf{x}}^{<k>} + \epsilon_k \bar{\mathbf{p}}_k$
- 计算  $\bar{\mathbf{g}}_{k+1} = \mathbf{g}(\bar{\mathbf{x}}^{<k+1>})$ 。若  $|\bar{\mathbf{g}}_{k+1}| < e$ ，则停止计算，得到近似解  $\bar{\mathbf{x}} = \bar{\mathbf{x}}^*$
- 否则计算，置  $k = k + 1$ 。由  $\mathbf{B}_k \bar{\mathbf{p}}_k = -\bar{\mathbf{g}}_k$  求出  $\bar{\mathbf{p}}_k$ ，迭代

5. BFGS 算法中，每一次  $\bar{\mathbf{x}}$  增加的方向是  $-\mathbf{B}_k^{-1} \nabla_k$  的方向。增加的幅度由  $\epsilon_k$  决定，若跨度过大容易引发震荡



## 5.3 Broyden 类算法

1. 若记  $\mathbf{G}_k = \mathbf{B}_k^{-1}$ ,  $\mathbf{G}_{k+1} = \mathbf{B}_{k+1}^{-1}$ ，则对式子

$$\mathbf{B}_{k+1} = \mathbf{B}_k + \frac{\bar{\mathbf{y}}_k \bar{\mathbf{y}}_k^T}{\bar{\mathbf{y}}_k^T \bar{\delta}_k} - \frac{\mathbf{B}_k \bar{\delta}_k \bar{\delta}_k^T \mathbf{B}_k}{\bar{\delta}_k^T \mathbf{B}_k \bar{\delta}_k}$$

使用两次 Sherman-Morrison 公式可得：

$$\mathbf{G}_{k+1} = (\mathbf{I} - \frac{\bar{\delta}_k \bar{\mathbf{y}}_k^T}{\bar{\delta}_k^T \bar{\mathbf{y}}_k}) \mathbf{G}_k (\mathbf{I} - \frac{\bar{\delta}_k \bar{\mathbf{y}}_k^T}{\bar{\delta}_k^T \bar{\mathbf{y}}_k})^T + \frac{\bar{\delta}_k \bar{\delta}_k^T}{\bar{\delta}_k^T \bar{\mathbf{y}}_k}$$

其中的向量  $\bar{\delta}_k, \bar{\mathbf{y}}_k$  都是列向量

2. 令 DFP 算法获得的  $\mathbf{G}_{k+1}$  的迭代公式记作

$$\mathbf{G}^{DFP} = \mathbf{G}_k + \frac{\bar{\delta}_k \bar{\delta}_k^T}{\bar{\delta}_k^T \bar{\mathbf{y}}_k} - \frac{\mathbf{G}_k \bar{\mathbf{y}}_k \bar{\mathbf{y}}_k^T \mathbf{G}_k}{\bar{\mathbf{y}}_k^T \mathbf{G}_k \bar{\mathbf{y}}_k}$$

由 BFGS 算法获得的  $\mathbf{G}_{k+1}$  的迭代公式记作

$$\mathbf{G}^{BFGS} = (\mathbf{I} - \frac{\bar{\delta}_k \bar{\mathbf{y}}_k^T}{\bar{\delta}_k^T \bar{\mathbf{y}}_k}) \mathbf{G}_k (\mathbf{I} - \frac{\bar{\delta}_k \bar{\mathbf{y}}_k^T}{\bar{\delta}_k^T \bar{\mathbf{y}}_k})^T + \frac{\bar{\delta}_k \bar{\delta}_k^T}{\bar{\delta}_k^T \bar{\mathbf{y}}_k}$$



他们都满足拟牛顿条件，所以他们的线性组合： $\mathbf{G}_{k+1} = \alpha \mathbf{G}^{DFP} + (1 - \alpha) \mathbf{G}^{BFGS}$  也满足拟牛顿条件，而且是正定的。其中  $0 \leq \alpha \leq 1$ 。

这样获得了一族拟牛顿法，称为 Broyden 类算法

3. Sherman-Morrison 公式：假设  $\mathbf{A}$  是  $n$  阶可逆矩阵， $\mathbf{\bar{u}}, \mathbf{\bar{v}}$  是  $n$  维列向量，且  $\mathbf{A} + \mathbf{\bar{u}}\mathbf{\bar{v}}^T$  也是可逆矩阵，则：

$$(\mathbf{A} + \mathbf{\bar{u}}\mathbf{\bar{v}}^T)^{-1} = \mathbf{A}^{-1} - \frac{\mathbf{A}^{-1}\mathbf{\bar{u}}\mathbf{\bar{v}}^T\mathbf{A}^{-1}}{1 + \mathbf{\bar{v}}^T\mathbf{A}^{-1}\mathbf{\bar{u}}}$$

## 六、约束优化

### 6.1 原理

- 在有的最优化问题中，希望输入  $\mathbf{x}$  位于特定的集合  $\mathbb{S}$  中，这称作约束优化问题。
  - 集合  $\mathbb{S}$  内的点  $\mathbf{x}$  称作可行解
  - 集合  $\mathbb{S}$  也称作可行域。
- 约束优化的一个简单方法是：对梯度下降法进行修改。
  - 每次迭代后，将得到的新的  $\mathbf{x}$  映射到集合  $\mathbb{S}$  中
  - 如果使用线性搜索：则每次只搜索那些使得新的  $\mathbf{x}$  位于集合  $\mathbb{S}$  中的那些  $\epsilon$ 
    - 另一个做法：将线性搜索得到的新的  $\mathbf{x}$  映射到集合  $\mathbb{S}$  中。
    - 或者：在线性搜索之前，将梯度投影到可行域的切空间内

### 6.2 KKT 方法

- 在约束最优化问题中，常常利用拉格朗日对偶性将原始问题转换为对偶问题，通过求解对偶问题而得到原始问题的解。
- 约束最优化问题的原始问题：

假设  $f(\mathbf{x}), c_i(\mathbf{x}), h_j(\mathbf{x})$  是定义在  $\mathbb{R}^n$  上的连续可微函数。考虑约束最优化问题：

$$\begin{aligned} \min_{\mathbf{x} \in \mathbb{R}^n} & f(\mathbf{x}) \\ \text{s.t.} \quad & c_i(\mathbf{x}) \leq 0, i = 1, 2, \dots, k; \quad h_j(\mathbf{x}) = 0, j = 1, 2, \dots, l \end{aligned}$$

可行域由等式和不等式确定

$$\mathbb{S} = \{\mathbf{x} \mid c_i(\mathbf{x}) \leq 0, i = 1, 2, \dots, k; \quad h_j(\mathbf{x}) = 0, j = 1, 2, \dots, l\}$$

#### 6.2.1 原始问题

- 引入拉格朗日函数：

$$L(\mathbf{x}, \vec{\alpha}, \vec{\beta}) = f(\mathbf{x}) + \sum_{i=1}^k \alpha_i c_i(\mathbf{x}) + \sum_{j=1}^l \beta_j h_j(\mathbf{x})$$

这里  $\vec{x} = (x^{(1)}, x^{(2)}, \dots, x^{(n)})^T \in \mathbb{R}^n$ ,  $\alpha_i, \beta_j$  是拉格朗日乘子,  $\alpha_i \geq 0$

◦  $L(\vec{x}, \vec{\alpha}, \vec{\beta})$  是  $\vec{x}, \vec{\alpha}, \vec{\beta}$  的多元非线性函数

2. 定义函数:

$$\theta_P(\vec{x}) = \max_{\vec{\alpha}, \vec{\beta} : \alpha_i \geq 0} L(\vec{x}, \vec{\alpha}, \vec{\beta})$$

其中下标  $P$  表示原始问题。则有:

$$\theta_P(\vec{x}) = \begin{cases} f(\vec{x}), & \text{if } \vec{x} \text{ satisfy original problem's constraint} \\ +\infty, & \text{or else.} \end{cases}$$

- 若  $\vec{x}$  满足原问题的约束, 则很容易证明  $L(\vec{x}, \vec{\alpha}, \vec{\beta}) = f(\vec{x}) + \sum_{i=1}^k \alpha_i c_i(\vec{x}) \leq f(\vec{x})$ , 等号在  $\alpha_i = 0$  时取到
- 若  $\vec{x}$  不满足原问题的约束:
  - 若不满足  $c_i(\vec{x}) \leq 0$ : 设违反的为  $c_{i0}(\vec{x}) > 0$ , 则令  $\vec{\alpha}_{i0} \rightarrow \infty$ , 有  $L(\vec{x}, \vec{\alpha}, \vec{\beta}) = f(\vec{x}) + \sum_{i=1}^k \alpha_i c_i(\vec{x}) \rightarrow \infty$
  - 若不满足  $h_j(\vec{x}) = 0$ : 设违反的为  $h_{j0}(\vec{x}) \neq 0$ , 则令  $\vec{\beta}_{j0} h_{j0}(\vec{x}) \rightarrow \infty$ , 有  $L(\vec{x}, \vec{\alpha}, \vec{\beta}) = f(\vec{x}) + \sum_{i=1}^k \alpha_i c_i(\vec{x}) + \vec{\beta}_{j0} h_{j0}(\vec{x}) \rightarrow \infty$

3. 考虑极小化问题:

$$\min_{\vec{x}} \theta_P(\vec{x}) = \min_{\vec{x}} \max_{\vec{\alpha}, \vec{\beta} : \alpha_i \geq 0} L(\vec{x}, \vec{\alpha}, \vec{\beta})$$

则该问题是与原始最优化问题是等价的, 即他们有相同的问题。

- $\min_{\vec{x}} \max_{\vec{\alpha}, \vec{\beta} : \alpha_i \geq 0} L(\vec{x}, \vec{\alpha}, \vec{\beta})$  称为广义拉格朗日函数的极大极小问题。
- 为了方便, 定义原始问题的最优值为:

$$p^* = \min_{\vec{x}} \theta_P(\vec{x})$$

## 6.2.2 对偶问题

1. 对偶问题: 定义  $\theta_D(\vec{\alpha}, \vec{\beta}) = \min_{\vec{x}} L(\vec{x}, \vec{\alpha}, \vec{\beta})$ 。考虑极大化  $\theta_D(\vec{\alpha}, \vec{\beta})$ , 即:

$$\max_{\vec{\alpha}, \vec{\beta} : \alpha_i \geq 0} \theta_D(\vec{\alpha}, \vec{\beta}) = \max_{\vec{\alpha}, \vec{\beta} : \alpha_i \geq 0} \min_{\vec{x}} L(\vec{x}, \vec{\alpha}, \vec{\beta})$$

- 问题  $\max_{\vec{\alpha}, \vec{\beta} : \alpha_i \geq 0} \min_{\vec{x}} L(\vec{x}, \vec{\alpha}, \vec{\beta})$  称为广义拉格朗日函数的极大极小问题。

2. 可以将广义拉格朗日函数的极大极小问题表示为约束最优化问题:

$$\begin{aligned} \max_{\vec{\alpha}, \vec{\beta} : \alpha_i \geq 0} \theta_D(\vec{\alpha}, \vec{\beta}) &= \max_{\vec{\alpha}, \vec{\beta} : \alpha_i \geq 0} \min_{\vec{x}} L(\vec{x}, \vec{\alpha}, \vec{\beta}) \\ s.t. \alpha_i &\geq 0, i = 1, 2, \dots, k \end{aligned}$$

称为原始问题的对偶问题。

3. 定义对偶问题的最优值:

$$d^* = \max_{\vec{\alpha}, \vec{\beta} : \alpha_i \geq 0} \theta_D(\vec{\alpha}, \vec{\beta})$$

### 6.2.3 原始问题与对偶问题关系

1. 定理一：若原问题和对偶问题具有最优值，则：

$$d^* = \max_{\vec{\alpha}, \vec{\beta} : \vec{\alpha}_i \geq 0} \min_{\vec{x}} L(\vec{x}, \vec{\alpha}, \vec{\beta}) \leq \min_{\vec{x}} \max_{\vec{\alpha}, \vec{\beta} : \vec{\alpha}_i \geq 0} L(\vec{x}, \vec{\alpha}, \vec{\beta}) = p^*$$

2. 推论一：设  $\vec{x}^*$  为原始问题的可行解，且  $\theta_P(\vec{x}^*)$  的值为  $p^*$ ； $\vec{\alpha}^*, \vec{\beta}^*$  为对偶问题的可行解， $\theta_D(\vec{\alpha}^*, \vec{\beta}^*)$  值为  $d^*$ 。

如果有  $p^* = d^*$ ，则  $\vec{x}^*, \vec{\alpha}^*, \vec{\beta}^*$  分别为原始问题和对偶问题的最优解。

3. 定理二：假设函数  $f(\vec{x})$  和  $c_i(\vec{x})$  为凸函数， $h_j(\vec{x})$  是仿射函数；并且假设不等式约束  $c_i(\vec{x})$  是严格可行的，即存在  $\vec{x}$ ，对于所有  $i$  有  $c_i(x) < 0$ 。

则存在  $\vec{x}^*, \vec{\alpha}^*, \vec{\beta}^*$ ，使得： $\vec{x}^*$  是原始问题  $\min_{\vec{x}} \theta_P(\vec{x})$  的解， $\vec{\alpha}^*, \vec{\beta}^*$  是对偶问题  $\max_{\vec{\alpha}, \vec{\beta} : \alpha_i \geq 0} \theta_D(\vec{\alpha}, \vec{\beta})$  的解，并且  $p^* = d^* = L(\vec{x}^*, \vec{\alpha}^*, \vec{\beta}^*)$

4. 定理三：假设函数  $f(\vec{x})$  和  $c_i(\vec{x})$  为凸函数， $h_j(\vec{x})$  是仿射函数；并且假设不等式约束  $c_i(\vec{x})$  是严格可行的，即存在  $\vec{x}$ ，对于所有  $i$  有  $c_i(x) < 0$ 。

则存在  $\vec{x}^*, \vec{\alpha}^*, \vec{\beta}^*$ ，使得  $\vec{x}^*$  是原始问题  $\min_{\vec{x}} \theta_P(\vec{x})$  的解， $\vec{\alpha}^*, \vec{\beta}^*$  是对偶问题  $\max_{\vec{\alpha}, \vec{\beta} : \alpha_i \geq 0} \theta_D(\vec{\alpha}, \vec{\beta})$  的解的充要条件是： $\vec{x}^*, \vec{\alpha}^*, \vec{\beta}^*$  满足下面的 Karush-kuhn-Tucker(KKT) 条件：

$$\begin{aligned}\nabla_{\vec{x}} L(\vec{x}^*, \vec{\alpha}^*, \vec{\beta}^*) &= 0 \\ \nabla_{\vec{\alpha}} L(\vec{x}^*, \vec{\alpha}^*, \vec{\beta}^*) &= 0 \\ \nabla_{\vec{\beta}} L(\vec{x}^*, \vec{\alpha}^*, \vec{\beta}^*) &= 0 \\ \vec{\alpha}_i^* c_i(\vec{x}^*) &= 0, i = 1, 2, \dots, k \\ c_i(\vec{x}^*) &\leq 0, i = 1, 2, \dots, k \\ \vec{\alpha}_i^* &\geq 0, i = 1, 2, \dots, k \\ h_j(\vec{x}^*) &= 0, j = 1, 2, \dots, l\end{aligned}$$

5. 仿射函数：仿射函数即由1阶多项式构成的函数。

一般形式为  $f(\vec{x}) = \mathbf{A}\vec{x} + b$ ，这里， $\mathbf{A}$  是一个  $m \times k$  矩阵， $\vec{x}$  是一个  $k$  维列向量， $b$  是一个  $m$  维列向量

◦ 它实际上反映了一种从  $k$  维到  $m$  维的空间映射关系。

6. 凸函数：设  $f$  为定义在区间  $I$  上的函数，若对  $I$  上的任意两点  $\vec{x}_1, \vec{x}_2$  和任意的实数  $\lambda \in (0, 1)$ ，总有  $f(\lambda\vec{x}_1 + (1 - \lambda)\vec{x}_2) \leq \lambda f(\vec{x}_1) + (1 - \lambda)f(\vec{x}_2)$  则  $f$  称为  $I$  上的凸函数